


Grouped Query Attention (4:1)



→ Quantisierungsfehler im KV-Head beeinflusst ALLE 4 Query-Heads