

KV-Cache Key-Kurtosis: Verteilung je Layer (Modellvergleich)

Linkes Panel: homogene Modelle | Rechtes Panel: Heavy-Tail-Modelle

Niedrige Kurtosis
(y: 0-20)

Hohe Kurtosis (Ausreißer)
(y: 0-160)

