


# VRAM-Analyse: absolut und relativ nach Quantisierungsstufe

## Absoluter VRAM-Verbrauch je Modell und Quantisierungsstufe



## Relative VRAM-Einsparung durch KV-Quantisierung

