


VRAM-Analyse: absolut und relativ nach Quantisierungsstufe

Absoluter VRAM-Verbrauch je Modell und Quantisierungsstufe



Relative VRAM-Einsparung durch KV-Quantisierung

